

**Máster de Formación Permanente en
Ciencia de Datos y Matemática Computacional**

Universidad de Almería

Memoria del Trabajo de Fin de Máster

**IMDb: Análisis exploratorio de datos mediante
bases de datos relacionales y visualización en
Power BI**

Julio 2026

Autora: Cristina Ganfornina Fuentes

Tutor: Manuel Torres Gil

Resumen

El presente Trabajo Fin de Máster aborda el diseño, la implementación y la explotación de una arquitectura de datos relacional en la nube para realizar un Análisis Exploratorio de Datos (EDA) sobre el sector cinematográfico, utilizando el dataset de referencia de IMDb. El pipeline de datos comienza con un proceso de Extracción, Transformación y Carga (ETL) desarrollado en Python, donde se depuran y unifican millones de registros históricos, aplicando un umbral de calidad de al menos 50 votos para mitigar el sesgo estadístico y optimizar la carga en la nube. A continuación, se define un modelo dimensional en estrella implementado físicamente en una base de datos gestionada en Aiven MySQL. Los datos son explotados analíticamente mediante consultas SQL avanzadas que integran agregaciones, subconsultas y funciones analíticas de ventana. Finalmente, los resultados de este análisis se consumen en Power BI Desktop, con un cuadro de mando interactivo. Este dashboard permite identificar con claridad tendencias analíticas de títulos, géneros cinematográficos y rendimiento de profesionales del sector.

Abstract

This Master's Thesis addresses the design, implementation, and operation of a relational data architecture in the cloud to perform an Exploratory Data Analysis (EDA) on the film industry, using the IMDb reference dataset. The data pipeline begins with an Extract, Transform, and Load (ETL) process developed in Python, where millions of historical records are cleaned and standardised, applying a quality threshold of at least 50 votes to mitigate statistical bias and optimise the cloud load. Next, a dimensional star schema is defined and physically implemented in a database managed in Aiven MySQL. The data is analysed using advanced SQL queries that incorporate aggregations, subqueries, and window analytic functions. Finally, the results of this analysis are visualised in Power BI Desktop with an interactive dashboard. This dashboard clearly identifies analytical trends in film titles, genres, and the performance of industry professionals.

Índice general

Introducción	2
Objetivos	3
1. Metodología	5
1.1. Tecnologías utilizadas e infraestructuras Cloud	5
1.2. Origen de los datos (IMDb Dataset)	6
1.3. Extracción, Transformación y Limpieza de datos (ETL)	6
1.4. Diseño del modelo dimensional (<i>Star Schema</i>)	8
1.5. Implementación y carga de datos	9
1.6. Modelo en Power BI	9
2. Resultados	10
2.1. Análisis exploratorio mediante consultas SQL	10
2.2. Desarrollo del Dashboard en Power BI	12
3. Conclusiones	19
3.1. Limitaciones del proyecto	19
3.2. Trabajo futuro	20
Bibliografía	21

Introducción

La industria cinematográfica ha experimentado una transformación importante a lo largo de la historia. Sin embargo, en las últimas décadas este cambio se ha acelerado de forma exponencial. La digitalización global y el auge de las plataformas de streaming han transformado totalmente la industria. Este nuevo modelo, además de cambiar los hábitos de consumo del público, ha generado un volumen de títulos que no para de crecer día a día.

En este escenario, las plataformas globales como IMDb (*Internet Movie Database*) se han convertido en los repositorios de información cinematográfica más representativos del mundo. La base de datos de IMDb acumula millones de títulos, que abarcan desde los primeros cortometrajes del siglo XIX hasta los estrenos más recientes de la cartelera actual, recopilando datos como títulos, géneros, calificaciones, volumen de votos, directores, actores y roles de producción.

Analizar esta información permite identificar patrones de éxito, comprender cómo han evolucionado los gustos del público a lo largo del tiempo, evaluar la trayectoria de los profesionales y, finalmente, tomar decisiones más informadas a la hora de producir nuevos proyectos.

Aunque la base de datos tiene un gran potencial, vamos a ver a continuación que el proceso de obtención y preparación de la información para su posterior explotación analítica presenta tres problemas que dificultan trabajar con ella en su estado original.

El volumen y tamaño de los archivos

Los datos oficiales de IMDb se distribuyen en bruto en formato TSV (*Tab-Separated Values*), alcanzan tamaños de varios gigabytes y contienen decenas de millones de filas. Al intentar trabajar con estos archivos mediante herramientas tradicionales como Microsoft Excel, el sistema se bloquea por la falta de memoria RAM.

Además, este volumen de datos conlleva un problema de costes de almacenamiento e infraestructura. Las instancias de bases de datos relacionales en la nube, como el plan para desarrolladores que ofrece Aiven MySQL, cuentan con limitaciones físicas de almacenamiento y RAM bastante estrictas. Subir los archivos TSV directamente a la nube sin un procesamiento previo de filtrado sería inviable.

La calidad de la información

El dataset original de IMDb se actualiza de forma colaborativa y diaria, lo que trae problemas de calidad de datos. Los archivos en bruto contienen valores nulos representados por el *string* literal `\N`, duplicados en las tablas de reparto, inconsistencias de formato y errores humanos (como series registradas con más de 100 temporadas o películas con duraciones absurdas de varios días). Trabajar con estos datos sin una depuración previa distorsionaría cualquier

métrica que intentáramos calcular.

El sesgo estadístico en las valoraciones

En IMDb coexisten superproducciones de Hollywood con películas amateur, videos domésticos o proyectos escolares. Esto genera un sesgo estadístico en las calificaciones de los usuarios. Una producción minoritaria con solo dos votos de personas allegadas al proyecto puede registrar una calificación de 10 sobre 10, superando en el ranking a un éxito de taquilla valorado con un 8.5 por más de un millón de espectadores.

Para que el análisis sea representativo del mercado real, tenemos que aplicar un filtro que descarte las obras que no tengan un mínimo de audiencia, estableciendo una condición de entrada de al menos 50 votos (`numVotes` $\geq$ 50). Esta criba soluciona el problema del tamaño de almacenamiento, reduciendo el volumen de registros a procesar a una escala más manejable.

Para dar solución a estos problemas, en este proyecto se descarta el análisis sobre los archivos planos y se propone la siguiente arquitectura:

1. **Proceso de ETL programado en Python:** Utilizamos Pandas a través de Jupyter Notebooks, con lo que podemos leer los datos en bruto mediante bloques, limpiar los nulos y los *outliers*, y reducir el tamaño de los ficheros antes de subirlos a Aiven.
2. **Almacenamiento en la nube (Aiven MySQL):** Implementamos un modelo dimensional en estrella en una base de datos cloud, por lo que tenemos la información accesible de forma constante, y se lee fácilmente gracias a las relaciones con claves primarias y foráneas.
3. **Explotación interactiva en Power BI:** Conectamos la base de datos de la nube directamente a Power BI utilizando el modo de importación en memoria (*Import*). Esto permite crear un modelo donde los filtros se aplican rápidamente, dando como resultado un cuadro de mando interactivo y visual.

Objetivos

El objetivo general de este proyecto es diseñar, implementar y explotar una arquitectura de datos relacional en la nube para realizar un Análisis Exploratorio de datos (EDA) sobre la industria cinematográfica, utilizando como fuente de datos el *dataset* público de *IMDb*.

Para alcanzar este objetivo general, el trabajo se estructura en torno a los siguientes objetivos específicos:

- Desarrollar en Python un flujo de *extracción, transformación y carga* (ETL), el cual debía limpiar el *dataset* original de IMDb, homogeneizar los tipos de datos primitivos, tratar los valores nulos y depurar anomalías o valores atípicos (*outliers*) en variables como las temporadas o la duración, para evitar el sesgo estadístico y el ruido analítico.
- Estructurar los datos limpios mediante un esquema dimensional (*Star Schema*), compuesto por dos tablas de hechos centrales, que recoge las métricas de negocio, y tablas de dimensiones planas que aportan el contexto.
- Implementar la base de datos en un entorno en la nube, en la plataforma Aiven MySQL, aprovechando la experiencia sobre las herramientas utilizadas previamente en el máster.
- Explotar y analizar los datos mediante SQL, realizando consultas analíticas sobre el motor de la base de datos para responder a preguntas clave, como los patrones históricos, índices de discrepancia entre el público y la crítica, y el comportamiento de las series a lo largo de sus temporadas.
- Construir un cuadro de mando interactivo en Power BI, conectado a nuestra base de datos en la nube.


Capítulo 1

Metodología

En este capítulo vamos a ver el proceso seguido para diseñar, preparar e implementar la base de datos en SQL orientada al análisis exploratorio de los datos de la plataforma cinematográfica IMDb.

1.1. Tecnologías utilizadas e infraestructuras Cloud

Con el objetivo de garantizar la escalabilidad, el rendimiento y la seguridad del proyecto, para este trabajo se ha seleccionado un *stack* tecnológico siguiendo un esquema sencillo de almacenamiento y explotación visual:



A continuación, se detalla la justificación técnica de cada componente del *stack*.

Python y Jupyter Notebooks

El proceso de Extracción, Transformación y Carga (ETL) se ha programado en Python 3, utilizando la interfaz de Jupyter Notebooks. Esta elección se basa en los siguientes motivos:

- El uso de la librería Pandas permite manipular las estructuras de datos (*dataframes*) de forma eficiente en memoria.
- Herramientas como SQLAlchemy y PyMySQL facilitan las conexiones a bases de datos, además de la inserción de registros en estas.
- Los cuadernos de Jupyter permiten integrar código ejecutable, visualizaciones intermedias y narrativa, facilitando la claridad del *pipeline*.

Aiven MySQL Cloud

Para el almacenamiento físico de la base de datos relacional, se ha optado por desplegar una instancia de MySQL en la plataforma en la nube Aiven. Esta base de datos actúa como *Data Warehouse* centralizado. Los motivos para esta elección han sido:

- La plataforma Aiven y su entorno cloud ya habían sido usados en asignaturas previas del plan de estudios de este máster, lo que ha minimizado el esfuerzo de la configuración inicial del entorno.
- Se trata de una solución basada en la nube, por lo que la base de datos es accesible de forma segura y constante desde cualquier dispositivo, facilitando la integración con Power BI.

Power BI

Se ha seleccionado Power BI como herramienta para la visualización de los datos y el análisis interactivo. Las ventajas principales de su uso en este trabajo han sido:

- La facilidad para la creación de relaciones complejas, jerarquías temporales y definición de métricas avanzadas mediante lenguaje DAX (*Data Analysis Expressions*).
- Power BI se conecta de forma nativa a la base de datos de Aiven MySQL, manteniendo con facilidad el cuadro de mando actualizado.

1.2. Origen de los datos (IMDb Dataset)

Los datos originales corresponden a los ficheros oficiales y públicos que IMDb actualiza diariamente para uso no comercial. Estos están disponibles en IMDb Developer. Se distribuyen en archivos planos en formato TSV (*Tab-Separated Values*) con codificación UTF-8.

El volumen inicial del dataset es bastante grande, superando varios gigabytes en texto plano, con decenas de millones de registros. Los principales ficheros extraídos para el análisis son:

- `title.basics.tsv`: Información básica de los títulos (películas, series, episodios), incluyendo títulos primarios, géneros, años de estreno y duración.
- `title.ratings.tsv`: Calificaciones promedio y número de votos acumulados para cada título.
- `title.episode.tsv`: Relación entre series de televisión y sus respectivos episodios (temporada y número de capítulo).
- `title.principals.tsv`: Elenco y equipo principal de producción asociado a cada título (actores, actrices, directores), detallando los personajes interpretados.
- `name.basics.tsv`: Información básica de los profesionales (nombre, año de nacimiento, año de fallecimiento y profesiones principales).

1.3. Extracción, Transformación y Limpieza de datos (ETL)

Debido al tamaño de los archivos TSV originales de IMDb, si intentamos cargarlos directamente se colapsaría la base de datos o se saturaría la memoria de la máquina local. Por ello, se ha implementado un flujo de filtrado, limpieza de anomalías y optimización de tipos de datos en Python.

Filtro de votos (reducción de ruido)

El volumen total de títulos registrados en IMDb supera los 10 millones. Estos incluyen producciones locales o videos domésticos sin interés analítico para nuestro estudio, que añaden un sesgo al análisis de calificaciones.

Para mitigar este problema, aplicamos un filtro de exclusión sobre la tabla de valoraciones (`H_RATINGS`). Definimos que un título solo será considerado válido si cumple la condición del umbral de votos $\text{numVotes} \geq 50$. Este filtrado reduce el número de títulos a 594.332 registros, un volumen más manejable y representativo. Esta reducción se propagó en cascada al resto de dimensiones, reduciendo también el peso de las tablas dependientes (`DIM_TITLES`, `H_PRINCIPALS` y `DIM_NAMES`) antes de escribirlas en disco.

Tratamiento de nulos y tipos de datos

Los archivos originales de IMDb representan los valores nulos mediante el string `\N`. Este patrón fue mapeado durante el proceso de lectura con Pandas, mediante la función:

```
pd.read_csv('...', sep='\t', na_values='\\N')
```

Posteriormente, se transformaron y optimizaron los tipos de datos primitivos de texto a formatos más eficientes:

- Los años de inicio y fin (`startYear`, `endYear`), así como los números de episodio y temporada, se forzaron a tipo numérico entero (`Int64`).
- Se autocompletaron los campos vacíos esenciales con valores genéricos como `'Unknown Genre'` o `'Untitled / Unknown'` para evitar fallos de visualización o de carga.

Eliminación de outliers y valores incoherentes

Durante el análisis exploratorio preliminar, detectamos inconsistencias graves en el dataset original que podrían romper las medias y KPIs posteriormente:

- Algunos títulos de series de televisión registraban números de temporada superiores a 100. En muchos casos, esto se debía a que se había introducido erróneamente el año de estreno en el campo de la temporada. Para solucionar este problema, se sustituyeron directamente por nulos (`pd.NA`) cualquier registro con `seasonNumber` ≥ 100 .
- Se identificaron también duraciones (`runtimeMinutes`) absurdas o extremas, como negativas, iguales a cero, o extremadamente largas. Se estableció para esto una regla con la que cualquier registro con duración menor o igual a 0, o que superara el límite de 8 horas (480 minutos), se reajustó a nulo (`pd.NA`) para evitar la distorsión de la media aritmética de la duración en el análisis.

Optimización de roles profesionales

La tabla de profesionales asociados a los títulos (`title.principals.tsv`) registra decenas de categorías profesionales por película (maquilladores, técnicos de sonido, productores, dobles

de acción, etc). Para optimizar el rendimiento y el almacenamiento de nuestra base de datos, se ha decidido filtrar y conservar únicamente las tres profesiones que aportan mayor valor directo al análisis exploratorio: actores (**actor**), actrices (**actress**) y directores (**director**). Este filtro redujo considerablemente el tamaño del archivo final del trabajo, acelerando la carga y optimizando el almacenamiento de la base de datos en Aiven.

1.4. Diseño del modelo dimensional (*Star Schema*)

Para la implementación del repositorio, hemos decidido diseñar un *modelo dimensional en estrella (Star Schema)*. Así, estructuramos la información de forma clara, con dos tablas de hechos (métricas y procesos medibles) y tablas de dimensiones (contexto), como se detalla en la figura 1.1:




Figura 1.1: Diseño del modelo dimensional en estrella para el repositorio de IMDb

Descripción de las tablas del modelo

Tabla de hechos central: H_RATINGS

Representa el evento de calificación de un título. Cada registro contiene las siguientes métricas:

- **titleID**: clave primaria y foránea a DIM_TITLES.
- **averageRating**: calificación promedio de los usuarios de 1 a 10.
- **numVotes**: número total de votos que respaldan la calificación.

Tabla de dimensión: DIM_TITLES

Almacena la información detallada de cada título. Esta tabla contiene un bucle autorreferencial mediante el campo `parentTitleID`, lo que nos ha permitido modelar en la misma tabla las series de televisión (`tvSeries`) vinculadas a cada uno de sus capítulos individuales (`tvEpisode`), facilitando el análisis por temporadas.

Tabla de dimensión: DIM_FECHA

Para poder analizar correctamente las series temporales, se extrajeron los años únicos de inicio de producción (`startYear`) y se modelaron en una dimensión independiente.

Tablas DIM_GENRES y H_TITLES_GENRES

En el origen, los géneros se almacenaban en la tabla de títulos en una sola columna con formato de texto separado por comas, de forma que no podíamos usarla para realizar un análisis de géneros. Para solucionarlo, implementamos una tabla puente intermedia:

- DIM_GENRES: Almacena cada género existente (`genreID`, `genreName`).
- H_TITLES_GENRES: Tabla puente que descompone cada relación a nivel de fila (`titleID`, `genreID`), de manera que posteriormente podremos filtrar con PowerBI las calificaciones de los títulos para cualquier género sin duplicar la información de descripción del título.

Tablas DIM_NAMES y H_PRINCIPALS

- DIM_NAMES: Contiene la información básica de los profesionales (`nameID`, `primaryName`, `birthYear`, `deathYear`, `primaryProfession`).
- H_PRINCIPALS: Actúa como tabla de hechos, registrando qué profesionales (`nameID`) participan en qué títulos (`titleID`), bajo qué rol principal (`category`) y el personaje que interpretan (`characters`).

1.5. Implementación y carga de datos

Una vez estructurados los *dataframes* limpios en Python y exportados temporalmente a ficheros CSV, se procedió a la migración hacia el entorno de Aiven. El proceso de inserción de los datos se automatizó mediante un script de carga, con el que inicialmente se vaciaron las tablas, de forma que evitamos duplicar registros al realizar una nueva carga, y posteriormente se realizaron las inserciones por bloques de 15.000 registros, para evitar caídas por *timeout*.

1.6. Modelo en Power BI

Finalmente, se integró la base de datos de Aiven en Power BI Desktop. Para maximizar el rendimiento y la velocidad de renderizado de las visualizaciones, se configuró el almacenamiento en modo *Import*. Así, se procesan las consultas complejas y filtrados en la propia aplicación, optimizando los recursos y la experiencia de usuario.

Capítulo 2

Resultados

En este capítulo se presentan y analizan los principales resultados obtenidos en el análisis exploratorio del modelo de IMDb. El análisis se ha dividido en dos aproximaciones complementarias:

- **Exploración conceptual con SQL:** se ha hecho un análisis de los patrones de negocio basándonos en consultas SQL con funciones de ventana, *CTEs* y filtros de agregación.
- **Exploración visual e interactiva en Power BI:** se ha diseñado un cuadro de mando interactivo para ayudar al análisis visual.

Nota: Todas las consultas SQL detalladas y ejecutadas en este apartado con su correspondiente código pueden consultarse en el cuaderno de Jupyter `sql_imdb.ipynb` en el repositorio del proyecto.

2.1. Análisis exploratorio mediante consultas SQL

Para extraer valor del repositorio de datos, se plantearon preguntas estratégicas que vamos a ver a continuación.

Análisis del volumen de producción y crecimiento año tras año (YoY)

El primer análisis se centra en comprender cómo evoluciona la producción cinematográfica global a lo largo del tiempo. Para responder a esto, se calculó la tasa de crecimiento año tras año (YoY) de forma comparativa, por un lado sobre todo el catálogo de producciones, y por otro lado aislando el formato de películas (`movie`).

Se obtienen las siguientes conclusiones principales:

- Por un lado, los datos muestran la parálisis que sufrió la industria como resultado de la COVID-19 en 2020. El volumen global de contenidos cayó un -10.78 %, y en concreto el sector de largometrajes sufrió una caída del -21.42 %, pasando de 6405 películas en 2019 a solo 5033 en 2020, debido al cierre de salas de cine y suspensiones de rodajes en todo el mundo.

- Por otro lado, podemos ver que tras la crisis, en 2021-2022 se produjo una reactivación del sector. En 2021, la producción general creció un 10.87%, y en 2022 el formato de películas tuvo un crecimiento del 16.64%, reflejando los estrenos de todos los proyectos que se habían pospuesto.

Comportamiento del consumidor: Índice de discrepancia por Géneros

El segundo análisis estudia el comportamiento y las preferencias del consumidor ante los distintos géneros cinematográficos. El objetivo es identificar qué temáticas funcionan solo como productos comerciales (gran interacción pero valoraciones modestas) frente a aquellas que podemos considerar obras de culto (con poca audiencia pero calificaciones altas).

Definimos el concepto de *índice de discrepancia* con el objetivo de medir el límite entre la opinión de la crítica y el nivel de interacción del público. Este indicador se define como la diferencia de posiciones que ocupa cada género teniendo en cuenta los dos factores: el de calificación media (`averageRating`) y el nivel de interacción (`numVotes`).

Se obtienen las siguientes conclusiones:

- Por un lado, entre los géneros populares, es decir, los que obtienen un índice de discrepancia positivo, destacan el thriller (+22) y la ciencia ficción (+21). Son temáticas que a la gente les gusta y tienen gran número de espectadores, con puestos 2 y 1 en volumen de interacción, pero que reciben valoraciones modestas por parte de la crítica (puestos 24 y 22 en nota media). En el género horror se observa un comportamiento similar, con un índice de +17 pero una nota media de 5.67.
- Por otro lado, entre las obras de culto, es decir, los que tienen una discrepancia negativa, podemos encontrar géneros como el documental o la biografía, que cuentan con un volumen de votos por título muy modesto, pero los que lo consumen los valoran con notas sobresalientes, situándolos en el Top 10 de *rankings* de notas medias.

Relación duración-calificación en Películas

A continuación, evaluamos la relación entre la duración de las películas y su calificación media, con el objetivo de comprobar si es verdad que las películas excesivamente largas cansan al espectador o si, por el contrario, estas se asocian a una mayor calidad. Para ello, se agruparon las películas del catálogo en cuatro rangos de duración.

En los resultados se observa una correlación positiva entre la duración de la película y la calificación.

Por un lado, las películas de duración comercial estándar (1h-2h) representan la gran mayoría del catálogo (154.804 títulos), pero registran la calificación promedio más baja de todas con un 5.89. Asimismo, las películas largas (2h-3h) consiguen una puntuación media de 6.51 y el cuádruple de votos promedio que el formato anterior (21.154 frente a 5.062). Finalmente, las súper producciones (>3h) son las que lideran la tabla, con una nota media de 7.03. Esto demuestra que las películas más largas suelen reservarse para proyectos con más presupuesto, y están dirigidas a un público más fiel.

Ciclo de vida del éxito en actores y directores

En este cuarto punto se analiza el ciclo de vida y madurez creativa de los profesionales (actores, actrices y directores). El objetivo de este análisis fue descubrir en qué franja de edad obtienen las mejores valoraciones por parte de la audiencia. Se calculó la edad de cada profesional en el año del estreno de cada una de sus películas, agrupándolos por rangos de edad.

El análisis muestra una clara diferencia en los ciclos de vida según el rol profesional. En el caso de los intérpretes, su éxito se concentra en las etapas más jóvenes, concretamente entre los 25 y los 44 años. En el caso de los actores, la calificación más alta se alcanza en el rango de 25-34 años (7.15). Por otro lado, en el caso de los directores se observa un éxito mucho más tardío. Sus notas más altas y su mayor volumen de producción no se alcanza hasta los rangos de 35 a 54 años. Esto demuestra que la experiencia del director influye positivamente en la calidad de su trabajo.

Evolución de la calidad entre temporadas en Series de TV

En este último punto, se evalúa la evolución de las series de televisión a medida que avanzan en número de temporadas, con el objetivo de identificar si sufren un desgaste de calidad o si consiguen consolidarse. Se calculó la diferencia en la calificación de cada temporada respecto a la anterior.

El análisis de estos resultados para las series con mayor éxito nos deja las siguientes conclusiones:

- Las series suelen mejorar la calificación temporada tras temporada durante las primeras etapas (temporadas 2 a 4). Un claro ejemplo es *Attack on Titan*, que tras un 8.81 en su primera temporada, sube a 9.09 en la segunda, y alcanza su pico en la tercera con un 9.30.
- Podemos ver un gran impacto en los finales, como en *Game of Thrones*, que tras alcanzar su máxima calificación en la temporada 4 con un 9.24, sufre una caída en su temporada final (Temporada 8), con un 6.40, es decir, una pérdida de -2.63 puntos en comparación con la temporada 7 (9.03).

2.2. Desarrollo del Dashboard en Power BI

Para visualizar estos resultados y poder interactuar con los datos, se ha desarrollado un cuadro de mando interactivo (Dashboard) en Power BI Desktop conectado con nuestra base de datos en Aiven.

Evolución temporal

La primera pantalla (Figura 2.1) está diseñada para entender el crecimiento histórico y la composición general de la base de datos.

- **Tarjetas de KPIs:** Muestran las tres métricas más importantes: 594.000 títulos, una nota media global de 6.87 y un volumen de votos de 2 mil millones.

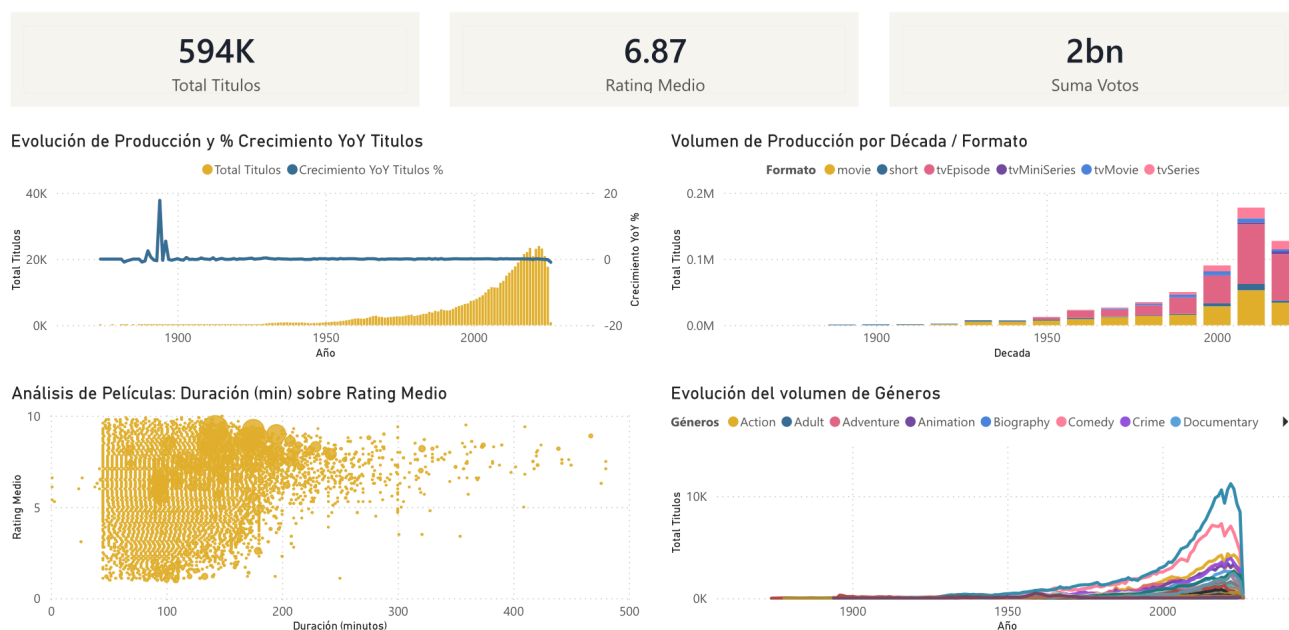


Figura 2.1: Dashboard Análisis Temporal en Power BI

- **Evolución de producción y % crecimiento YoY:** muestra el volumen anual de títulos (columnas amarillas) frente a su variación (línea azul). Muestra el crecimiento exponencial de la producción a lo largo de la historia.
- **Volumen de producción por década:** muestra un cambio radical en los hábitos de consumo en las últimas décadas. Podemos ver cómo el formato de episodio de televisión (tvEpisode) crece exponencialmente sobre el formato de películas.
- **Duración en minutos sobre rating medio:** permite visualizar la correlación de la duración frente a la valoración. Podemos ver la concentración de películas comerciales entre 80 y 120 minutos, y cómo los puntos correspondientes a obras más largas tienden a mantenerse sobre el rango de notas de 7 a 9.
- **Evolución del volumen de Géneros:** desglosa la producción anual según el género. Permite identificar las épocas doradas de cada género y observar cómo la diversificación y el volumen de contenido explotan a partir de la década de 1990, evolucionando de forma mucho más destacable géneros como el drama y la comedia.

Popularidad de géneros

Esta pestaña (Figura 2.2) permite analizar el rendimiento de los diferentes géneros:

- **Tabla de clasificación de la audiencia:** Podemos ver las métricas de cada género y la clasificación de la audiencia mediante el índice de discrepancia.
- **Desviación de rating por género:** Muestra la diferencia de calificación de cada temática frente a la nota media global (6.87). Podemos ver cómo los géneros de Animación,

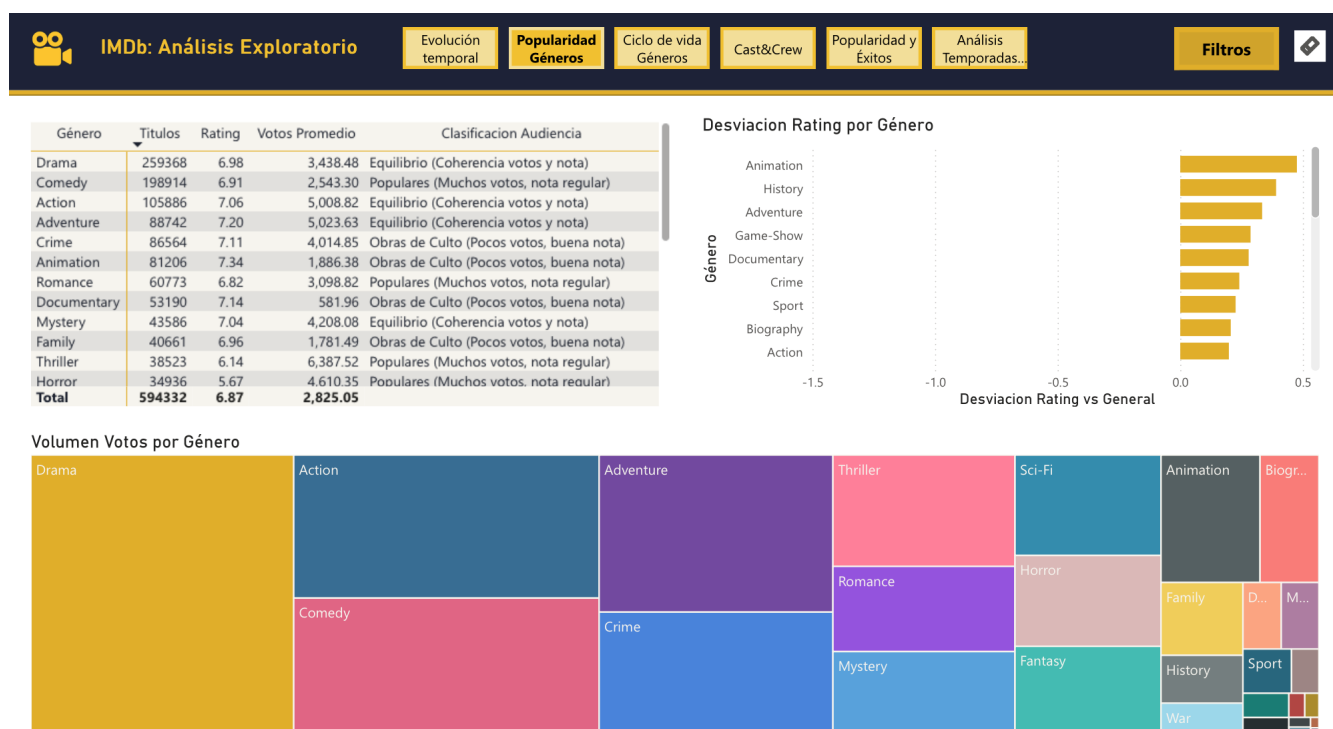


Figura 2.2: Dashboard Popularidad de géneros en Power BI

Historia y Aventura tienen las desviaciones positivas más notables.

- **Volumen de votos por género:** Muestra el *engagement* de cada género. Podemos ver que el Drama, la Acción y la Comedia son los géneros más populares, acumulando casi la mitad de los votos emitidos en la plataforma.

Ciclo de vida de géneros

Esta tercera pantalla (Figura 2.3) se ha diseñado para evaluar la evolución temporal de los géneros a lo largo de la historia de la industria.

- **Tarjetas de KPIs:** Tenemos un total de 28 géneros únicos en el dataset. Además, los géneros más cortos en la historia han sido los Talk-Shows, Reality-TV y Film-Noir, siendo este último el más corto con diferencia. Por otro lado, los más duraderos y que, como podemos ver en la tabla de abajo, siguen vigentes, son los Short, Documentary y History.
- **Gráfico de rango y tabla de estado:** Se muestra visualmente los años de actividad de cada género, junto con una tabla detallada que incluye el año de debut del género, el último año registrado, y el estado actual del género. Así, podemos ver cómo la evolución tecnológica ha dado lugar a nuevos géneros, como el Reality-TV, mientras otros han quedado inactivos desde hace varias décadas.

Cast & Crew (el factor humano)

Esta pestaña (Figura 2.4) muestra el impacto de los intérpretes y directores en el éxito de los títulos:




Figura 2.3: Dashboard Ciclo de vida de géneros en Power BI

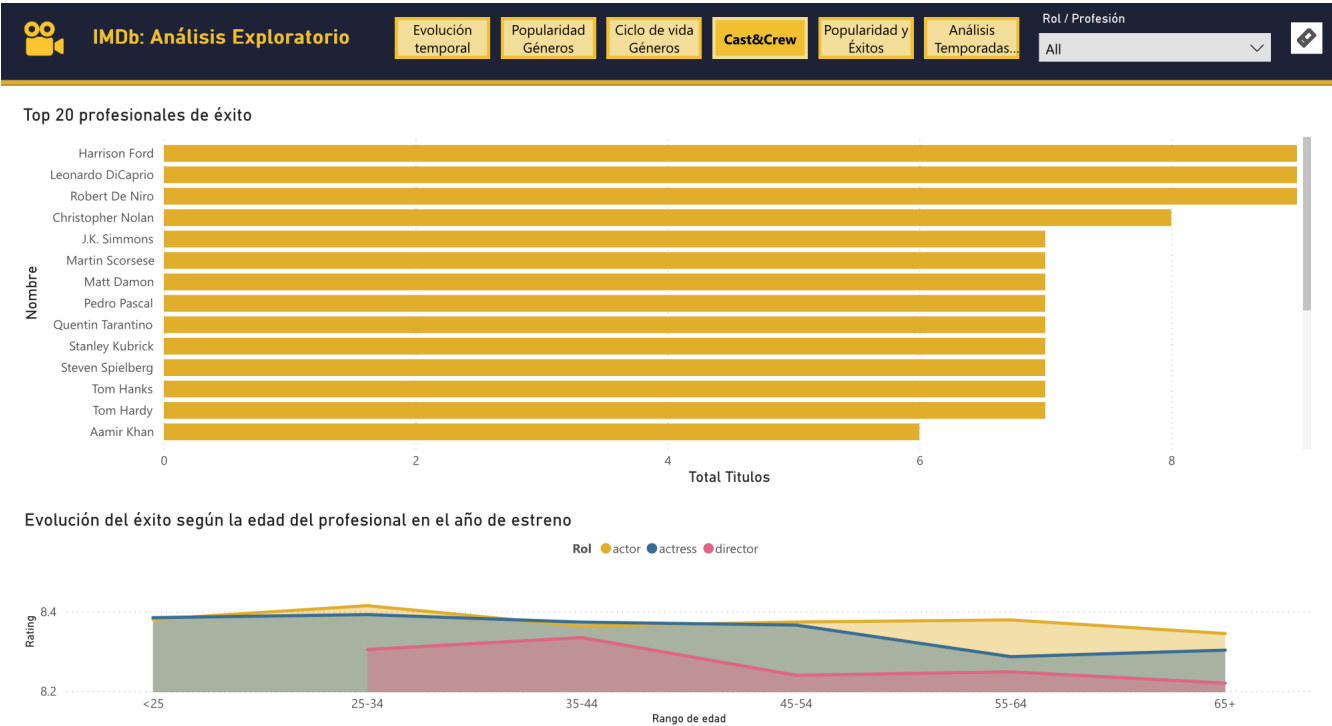


Figura 2.4: Dashboard Cast & Crew en Power BI

- **Ranking de profesionales de éxito:** En el gráfico de barras horizontales se destaca a los artistas que acumulan mayor número de producciones excelentes (notas ≥ 8 y más de 100mil votos). Encabezan el ranking figuras muy conocidas como Harrison Ford, Leonardo DiCaprio y Robert De Niro, y directores importantes como Christopher Nolan.
- **Evolución del éxito según la edad del profesional en el estreno:** Muestra visualmente las curvas de calificación según el rango de edad y el rol profesional. Confirma los resultados de las consultas de SQL: los actores y actrices registran sus picos de éxito en edades tempranas y los directores consiguen mayor éxito a partir de los 35 años.

Popularidad y éxito de títulos




Figura 2.5: Dashboard Popularidad y éxitos del formato series en Power BI

Esta vista (Figuras 2.6 y 2.5) se ha diseñado para analizar la relación entre el volumen de visualización y la valoración de los títulos. En el gráfico de dispersión (*Scatter Plot*) podemos ver las obras según su Rating Medio (eje X) y sus Votos Totales (eje Y). Así, podemos identificar de forma visual qué producciones logran tanto la excelencia en cuanto a rating como un gran número de visualizaciones. Para facilitar el análisis, se ha añadido un selector de formato, de forma que vemos por separado los resultados para series y películas:

- **Series de Televisión (tvSeries):** En la Figura 2.5, podemos ver que *Game of Thrones* se consolida como la serie más popular (con el mayor volumen de votos acumulados en la plataforma, rozando los 2.5 millones). Por otro lado, *Breaking Bad* destaca como la producción con mayor éxito para la crítica (con un rating medio superior a 9.5 y un volumen de votos muy similar al anterior).




Figura 2.6: Dashboard Popularidad y éxitos del formato películas en Power BI

- **Películas (movie):** En la Figura 2.6, el escenario varía considerablemente. *The Shawshank Redemption* (*Cadena Perpetua*) destaca liderando ambas métricas, consolidándose como la película más votada de la plataforma (superando los 2.7 millones de votos) y, a su vez, como la que registra la calificación media más alta de todo el conjunto de datos (9.3).

Series de TV y ciclo de vida

Esta pantalla (Figura 2.7) se diseñó para visualizar el comportamiento de las series de televisión a lo largo de sus temporadas, utilizando un filtro de selección de series individuales:

- **Ciclo de vida de la serie:** Al seleccionar una serie podemos visualizar la evolución de su nota media por temporada (columnas amarillas) frente a la línea de tendencia del mercado global en cada temporada (línea azul). En el caso de *Game of Thrones*, podemos ver el éxito continuo durante sus primeras 7 temporadas, manteniéndose bastante por encima de la media del mercado, y luego la caída en su octava temporada, que baja a una calificación de 6.40.
- **Series globales activas por temporada:** Es una curva de supervivencia de las series de televisión. Muestra cómo la mayoría de las series termina tras su primera temporada. Llegar a producir 8 temporadas de una serie es muy poco común.
- **Tabla de detalle y detección de episodios outliers:** La tabla de la parte inferior desglosa cada episodio de la serie seleccionada, calculando su desviación con respecto al promedio general de la serie (8.75 en el caso de *Game of Thrones*). Esto permite identificar qué capítulos marcaron tanto de forma positiva como negativa la serie en cuestión.



Figura 2.7: Dashboard Análisis de temporadas de series en Power BI

Capítulo 3

Conclusiones

En este último capítulo se exponen las conclusiones generales del proyecto, se detallan las limitaciones que hemos encontrado a nivel técnico durante el desarrollo y se proponen mejoras viables de cara al futuro.

Tras completar todo el proceso, podemos confirmar que la arquitectura elegida funciona correctamente y cumple con los objetivos de eficiencia, escalabilidad y accesibilidad que nos habíamos propuesto. Usar Python y la librería Pandas para procesar los datos por bloques resultó ser la única forma viable de trabajar con gigabytes de información, evitando los cuellos de botella y los bloqueos que sufríamos al intentar abrir los archivos originales con Excel. Además, al alojar la base de datos en Aiven MySQL, evitamos que el proyecto dependa de un disco duro local y que la información sea accesible de forma segura desde cualquier sitio, además de que facilita conectar Power BI directamente a la nube.

Por otro lado, la decisión de filtrar el catálogo para quedarnos solo con películas y series que tuviesen al menos 50 votos ($\text{numVotes} \geq 50$) nos ha servido para limpiar el ruido de miles de títulos totalmente desconocidos que habrían falseado los promedios de las notas, además de optimizar el tamaño de los datos a un volumen más manejable, con 594.332 registros. Gracias a esta optimización, el modelo dimensional cabe perfectamente dentro de las limitaciones de almacenamiento del plan gratuito de Aiven MySQL y las consultas SQL se ejecutan muchísimo más rápido.

3.1. Limitaciones del proyecto

Durante el desarrollo de este trabajo hemos tenido algunas limitaciones técnicas. En primer lugar, al usar el plan gratuito para desarrolladores de Aiven MySQL, el espacio de almacenamiento en disco está bastante limitado. Aunque en nuestro caso el filtro de los 50 votos solucionó este problema, en un entorno empresarial real con un volumen de datos mucho más grande sería obligatorio contratar un plan de pago para poder guardar todo el histórico sin aplicar filtros de exclusión. Asimismo, el rendimiento de la actualización de Power BI depende de la velocidad de la red. Aunque la navegación por el dashboard es rápida gracias al modo *Import*, cuando queremos actualizar los datos el sistema tiene que descargarse de golpe cientos de megabytes desde la base de datos cloud a nuestro ordenador local, lo que puede ralentizar el proceso si la conexión a internet es lenta.

En segundo lugar, una de las limitaciones más importantes del dataset oficial en bruto de

IMDb es que no incluye un campo estructurado con el país de origen de la producción. Esto nos ha impedido realizar un análisis espacial o un mapa de la producción cinematográfica por países. Por último, existe una gran dependencia respecto al formato de origen. Como consumimos directamente los datos planos que distribuye IMDb, dependemos por completo de que ellos no alteren la estructura de sus archivos TSV o los nombres de sus columnas en las actualizaciones diarias, ya que cualquier modificación rompería nuestro script de Python y nos obligaría a corregir el código manualmente.

3.2. Trabajo futuro

Como continuación de este proyecto, se proponen tres líneas de trabajo futuro muy viables. La primera de ellas es la planificación de la ejecución automática del script de Python. Para lograrlo, bastaría con guardar nuestro cuaderno de Jupyter como un script ejecutable de Python normal (.py) y programar su ejecución periódica en el sistema. Esta mejora automatizaría la limpieza de los datos y evitaría tener que arrancar el proceso a mano cada vez que IMDb actualice sus archivos en la red.

La segunda propuesta consiste en cruzar nuestra base de datos con cifras económicas. El beneficio de esta línea de trabajo sería poder analizar qué géneros, directores o actores son los más rentables económicamente y no solo los mejor valorados por el público. Para hacerlo, buscaríamos un dataset complementario de presupuestos y ganancias en taquilla y lo uniríamos a nuestro modelo dimensional.

Por último, se propone la incorporación del análisis geográfico para solucionar la limitación de origen comentada anteriormente. El beneficio directo para el negocio sería poder diseñar mapas interactivos en Power BI para ver visualmente qué países producen más y dónde se concentran los títulos mejor valorados. Para llevar a cabo esta ampliación, importaríamos un archivo externo que asocie cada `titleID` con su país de origen, integrando esta nueva dimensión en el modelo relacional para habilitar una pestaña visual de mapas en el cuadro de mando.

Bibliografía

- [1] Aiven. *Aiven for MySQL: Fully managed cloud database*. <https://aiven.io/mysql>
- [2] IMDb. *IMDb Developer Datasets: Non-commercial licensing*. IMDb Developer. <https://developer.imdb.com/non-commercial-datasets/>
- [3] Microsoft. *Power BI Desktop: Documentación oficial de diseño y modelado*. Microsoft Learn. <https://learn.microsoft.com/es-es/power-bi/>
- [4] Oracle. *MySQL 8.0 Reference Manual: Window Function Descriptions*. Oracle Help Center. <https://dev.mysql.com/doc/refman/8.0/en/window-functions.html>
- [5] Russo, M., & Ferrari, A. (2019). *The Definitive Guide to DAX: Business intelligence with Microsoft Power BI, SQL Server Analysis Services, and Excel* (2nd ed.). Microsoft Press.
- [6] The Pandas Development Team. *pandas: Powerful data analysis and manipulation library for Python*. <https://pandas.pydata.org/docs/>